

Segmentação de Rotas Apache Camel Java DSL

Análise não supervisionada de classes Java

Gil César Faria – Dezembro de 2025

Introdução


Problema: encontrar rotas semelhantes para facilitar desenvolvimento.

Abordagem não supervisionada com PCA e TSNE 2D e UMAP 2D e 3D

Clusterização com DBSCAN e HDBSCAN

Objetivo: encontrar grupos semânticos coesos.

Protocolo e Metodología



Base de Dados


- 1734 classes Java, cada uma representando uma Rota Apache Camel
- Projeto real, código fonte fechado, não permitindo compartilhamento
- Morfologia de uma rota Apache Camel

Pré-Processamento

- Java -> LLM -> Descrição Semantica (JSON)
- Limpeza e revisão dos JSON (170 de 1700 revisados manualmente)
- Descrição Semantica -> Embedding

PCA

Ausência de linearidade
faz com que o modelo
não gere boas projeções
para clusterização




Grupos DBSCAN

- Ruído
- Cluster 0
- Cluster 1


T-SNE

Captura alguns grupos
porém não abre bem um
grupo importante de rotas



UMAP 2D


- Se assemelha a T-SNE 2D, porém com melhor separação de grupos
- HDBSCAN sobre UMAP 2D sugere explorar UMAP 3D



UMAP 3D

- UMAP 3D mostra melhor os grupos
- Um grande grupo com pouca separação clara mostra limitação do método
- HDBSCAN mostra dois patamares claros de separação
- Explorar melhor o grande cluster:
 - GridSearch mais agresivo?
 - Separar o cluster em alta dimensão e reaplicar UMAP com novos parametro


Config 1 — HDBSCAN 3D (clusters=11)
trustworthiness=0.9540
(mcs=20, min_samples=4, method=eom, epsilon=0.0, noise=0.0173)



Supercluster

- Aplicar HDBSCAN apenas sobre o supercluster com parâmetros mais específicos resulta em duas vertentes:
 - Quantidade de clusters e ruído explode
 - Cluster colapsa em um grande grupo coeso

Supercluster — Config 1
clusters=25, noise=26.24%
(mcs=10, min_samples=3, method=eom, epsilon=0.0)




Clusters HDBSCAN — nível 2

- Ruído (n=253)
- Cluster 0 (n=10)
- Cluster 1 (n=11)
- Cluster 2 (n=18)
- Cluster 3 (n=12)
- Cluster 4 (n=10)
- Cluster 5 (n=108)
- Cluster 6 (n=14)
- Cluster 7 (n=61)
- Cluster 8 (n=39)
- Cluster 9 (n=14)
- Cluster 10 (n=13)
- Cluster 11 (n=25)
- Cluster 12 (n=10)
- Cluster 13 (n=19)
- Cluster 14 (n=50)
- Cluster 15 (n=14)
- Cluster 16 (n=60)
- Cluster 17 (n=39)
- Cluster 18 (n=28)
- Cluster 19 (n=38)
- Cluster 20 (n=20)
- Cluster 21 (n=12)
- Cluster 22 (n=29)
- Cluster 23 (n=37)
- Cluster 24 (n=20)

Supercluster

- Aplicar Agglomerative Clustering ignora densidade e permite separar de forma mais adequada o supercluster


Dendrograma — Agglomerative (Supercluster)



Supercluster

- Altura de corte 12 gera 6 clusters, grupos estão começando a apresentar fronteiras pouco estáveis


Agglomerative — corte distância=12.0 (k=6)



Supercluster

- Altura de corte 14 gera 5 clusters, grupos começam a apresentar fronteiras estaveis, mas ainda cabe ajuste


Agglomerative — corte distância=14.0 (k=5)



Supercluster

- Altura de corte 16 gera 4 clusters, grupos estão bem formados e estáveis

Agglomerative — corte distância=16.0 (k=4)



Clusterização Final

- Versão final consolidada em 2 níveis: primeiro grandes grupos por densidades, depois separa grande grupo por aglomeração

HDBSCAN (global) + Agglomerative (abertura do supercluster)

